

# Criando índice de eficiência com dados jurídicos

Matheus Souto

## Eficiência x Justiça

Juízes analisam milhares de casos durante anos de trabalho, sendo possível que a decisão seja contestada ou não. A classificação de juízes em um critério de eficiência quanto aos casos julgados seria muito importante em um país como o Brasil, com elevada diversidade e Constituição extensa.

Os casos analisados podem ser monitorados e, a partir dos mesmos, salientar quais seriam mais ou menos eficientes, trazendo um indicativo simples e direto para a sociedade de custo-benefício. Além disso, juízes mais eficientes poderiam ser bonificados e os menos eficientes punidos.

Com o intuito de fazer essa classificação, 40 juízes tiveram seus casos monitorados por um período de três anos, totalizando 182.908 casos julgados. Os casos faziam parte das esferas: cível, criminal e fazenda pública. Além disso, aqueles que foram apelados e/ou revertidos diante do veredito apresentado podem resultar de erros de juízes de instâncias iniciais.

A fim de identificar quais juízes estão tendo um bom desempenho em seu trabalho ou não, avaliou-se os dados fornecidos. A classificação dos juízes também é feita, fornecendo indicadores para o setor jurídico estadual.

Para que seja possível classificar os juízes de acordo com sua eficiência, foi elaborado um ranking que leva em consideração o número de casos julgados por cada juiz e a probabilidade de que um caso que foi julgado por determinado juiz seja apelado e, posteriormente, revertido. Uma vez que a reversão de um caso gera indícios de que houve algum erro de julgamento nas instâncias inferiores, a probabilidade de reversão dos casos de um juiz pode ser um bom indicador da eficiência do mesmo.

Para essa análise, a base de dados abaixo será utilizada. Nela, estão o total de casos julgados, casos que foram apelados e casos que foram revertidos de cada juiz.

```
head(dados)
```

```
## # A tibble: 6 x 6
##   Juiz   Julgados Apelados Revertidos Esfera indice
##   <chr>   <dbl>   <dbl>     <dbl> <chr>   <dbl>
## 1 J1      3037     137       12 Cível    1
## 2 J2      3372     119       10 Cível    2
## 3 J3      1258      44        8 Cível    3
## 4 J4      1954      60        7 Cível    4
## 5 J5      3138     127        7 Cível    5
## 6 J6      2264      91       18 Cível    6
```

## Relação entre casos Apelados e Revertidos


Durante o processo de criação foram calculadas as probabilidades de um caso ser apelado e revertido para cada juiz. A probabilidade de um caso ser apelado em relação ao total de casos julgados é de 1,29%.

```
sum(dados$Apelados)/sum(dados$Julgados)*100
```

```
## [1] 1.29464
```

Quando se trata dessa probabilidade para cada juiz, pode-se destacar J38 como o que possui menor probabilidade (0,002%) e J13, que possui a maior probabilidade de ter um caso apelado (0,079%). Dentro dos casos apelados, isso significa que 0,17% foi apelado pelo J38 e 6,12% pelo J13, respectivamente.

```
dados$prob_apelacao <- dados$Apelados/sum(dados$Julgados)*100
dados$prob_reverter <- dados$Revertidos/sum(dados$Julgados)*100
p<-ggplot(data=dados, aes(y=prob_apelacao, x=reorder(Juiz,indice))) +
  geom_bar(stat="identity", fill="steelblue")+
  labs(y='Probabilidade de apelação', x='Juiz')+
  theme_minimal()
p + theme(axis.text.x = element_text(angle = 90, vjust = 0.5, hjust=1))
```




Já para os casos revertidos, sua proporção em relação ao total de casos julgados foi de 0,17%.

```
(sum(dados$Revertidos)/sum(dados$Julgados))*100
```

```
## [1] 0.1749513
```

J25 e J26 foram os juízes com menor percentual de reversão, ao passo que J8 (0,109%) e J7 (0,120%) foram os juízes com maior probabilidade de reversão.

```
q<-ggplot(data=dados, aes(y=prob_reverter, x=reorder(Juiz,indice))) +
  geom_bar(stat="identity", fill="steelblue")+
  labs(y='Probabilidade de reversão', x='Juiz')+
  theme_minimal()
q + theme(axis.text.x = element_text(angle = 90, vjust = 0.5, hjust=1))
```




Dentre os casos apelados, 13,51% foram revertidos. Desse total, J7 é o que teve maior reversão considerando a condição de ter sido apelado e os juízes J25 e J26 apresentam menor grau de reversão. É importante salientar que essa estatística pode não ser a mais eficiente para ranquear os juízes pois ela traz uma relação da quantidade revertida pelo juiz em questão, em relação ao total de apelados.

```
(sum(dados$Revertidos)/sum(dados$Apelados))*100
```

```
## [1] 13.51351
```

```
dados$condicional<-dados$Revertidos/sum(dados$Apelados)
u<-ggplot(data=dados, aes(y=condicional, x=reorder(Juiz,indice))) +
  geom_bar(stat="identity", fill="steelblue")+
  labs(y='Probabilidade de reversão condicional', x='Juiz')+
  theme_minimal()
u + theme(axis.text.x = element_text(angle = 90, vjust = 0.5, hjust=1))
```



#Índice de eficiência

O índice de eficiência dos juízes leva em consideração o número de casos de julgados e a probabilidade de reversão, dado que foi julgado pelo juiz em questão. Isso significa que o juiz mais eficiente será aquele que teve o maior número de casos julgados e o menor probabilidade de reversão. Para o cálculo desse índice, foi realizada uma padronização dos dados, isso significa que, quanto mais eficiente for um juiz mais próximo de 1 será o seu score. Enquanto o juiz que está mais próximo do 0 teve um número baixo de casos julgados e um número elevado de casos revertidos.

O cálculo desse índice foi feito a partir da padronização do número de casos julgados e da probabilidade de ser revertido dado que foi apelado. Posteriormente, realizou-se uma média ponderada desses dados para obter o índice. De acordo com o índice, J19 foi o juiz mais eficiente, enquanto que J14 foi o menos eficiente.

```
dados$prob_reversao_condicional<-dados$Revertidos/dados$Julgados*100
for(i in 1:40){
  dados$prob_reversao_padronizada[i]<- (dados$prob_reversao_condicional[i] - min(dados$prob_reversao_condicional)) / (max(dados$prob_reversao_condicional) - min(dados$prob_reversao_condicional))
  i<-i+1
}
```

## Warning: Unknown or uninitialised column: `prob\_reversao\_padronizada`.

```
for(i in 1:40){
  dados$julgados_padronizado[i]<- (dados$Julgados[i] - min(dados$Julgados)) / (max(dados$Julgados) - min(dados$Julgados))
  i<-i+1
}
```

## Warning: Unknown or uninitialised column: `julgados\_padronizado`.

```
dados$score<-0
for(i in 1:40){
  dados$score[i]<-((1-dados$prob_reversao_padronizada[i])*0.5)+(dados$julgados_padronizado[i]*0.5)
```

```

i<-i+1
}
library(dplyr)

##
## Attaching package: 'dplyr'

## The following objects are masked from 'package:stats':
##
##   filter, lag

## The following objects are masked from 'package:base':
##
##   intersect, setdiff, setequal, union

library(knitr)
print( arrange(dados[,c(1,13)], desc(dados$score)), n = 40)

## # A tibble: 40 x 2
##   Juiz   score
##   <chr> <dbl>
## 1 J19   0.989
## 2 J18   0.778
## 3 J31   0.762
## 4 J27   0.759
## 5 J22   0.755
## 6 J30   0.753
## 7 J23   0.751
## 8 J21   0.749
## 9 J35   0.705
## 10 J20   0.685
## 11 J25   0.679
## 12 J3    0.678
## 13 J37   0.648
## 14 J36   0.632
## 15 J33   0.581
## 16 J29   0.574
## 17 J32   0.568
## 18 J26   0.566
## 19 J24   0.563
## 20 J28   0.560
## 21 J17   0.556
## 22 J38   0.543
## 23 J4    0.515
## 24 J16   0.496
## 25 J11   0.490
## 26 J34   0.489
## 27 J5    0.484
## 28 J2    0.459
## 29 J1    0.398
## 30 J15   0.393
## 31 J12   0.391
## 32 J9    0.387
## 33 J10   0.372
## 34 J4    0.371

```

##	35	J13	0.325
##	36	J8	0.261
##	37	J7	0.240
##	38	J3	0.209
##	39	J6	0.175
##	40	J14	0